

Gemma 3 270M 基于 LoRA 的 SVG 徽标生成

姓名	敖炜
学号	202521080810
日期	2026-07-14

摘要

将 217 条可用记录固定分为 195 条训练和 22 条开发数据，对 Gemma 3 270M 进行 LoRA 监督微调；17 条最终验证样本完全隔离。总 reward 从 0.0235 提高到 0.2882，但人工渲染显示多数非致命输出仍退化为单色背景。因此结论是“格式稳定性明显改善，视觉语义生成仍未成功”。

1. 数据、训练与评测设计

原始 219 条中的两条 placeholder 目标相互冲突，仅在加载时过滤，源 JSONL 不修改。模型使用自带 chat template，system/user/padding token 的标签均为 -100，只有 assistant SVG token 计算损失。最终训练使用每个目标的前三个可见图元作为课程式派生目标，以降低 270M 模型的长序列难度。LoRA 仅插入 q/k/v/o 投影层；MPS 上使用 batch 1、梯度累积和梯度检查点。固定评测为 greedy、单 beam、最多 2048 个新 token。

2. Reward 设计

分项	权重	关键检查
语法与安全	30%	单一可解析 SVG；无脚本、外链和事件
几何	20%	viewBox、有限数值、主体坐标
结构与样式	15%	图元、颜色、调色板、非空白
提示词保真	25%	颜色、可验证图元词、基本构图
反退化	10%	截断、异常长度、模板泄漏、重复

Reward v2 要求正确 SVG namespace，并检查画布内前景、重复图元、巨型背景与折叠路径。背景/空白退化的 total 上限为 0.35；致命 XML/安全错误上限为 0.10。仍需渲染图进行 Goodhart 检查。

3. 受控实验

实验	r	lr	长度	样本	epoch	eval loss	秒
E0 default	8	2.0e-04	2048	110	1.0	1.1858	514
E1 r=4	4	2.0e-04	2048	110	1.0	1.1824	524
E2 r=16	16	2.0e-04	2048	110	1.0	1.1859	560
E3 lr=1e-4	8	1.0e-04	2048	110	1.0	1.3055	562
E4 lr=5e-4	8	5.0e-04	2048	110	1.0	1.0509	552
E5 len=3072	8	2.0e-04	3072	110	1.0	1.3901	632
E6 full-4ep	4	5.0e-04	2048	195	4.0	0.7251	-
E7 seed=123	4	5.0e-04	2048	195	1.0	0.9051	-
E8 shortest-110	4	2.0e-04	1536	110	3.0	0.9573	671
E9 six-elements	4	2.0e-04	1536	195	3.0	0.7196	705
E10 final-3elem	4	2.0e-04	1024	195	2.0	0.6773	357

E6/E7 从已有 checkpoint 独立重载评测，故不把重载耗时冒充训练耗时。完整目标虽有更低 dev loss，但生成经常截断；E10 的三图元课程在内部生成检查上 fatal rate 为 0，因此被冻结为最终 adapter。

4. 最终验证结果

指标	基座	LoRA	差值	95% CI	改善/平/退
总分	0.0235	0.2882	0.2647	[0.1971, 0.3206]	14/3/0
有效性	0.0688	0.7028	0.6340	[0.4633, 0.7890]	14/3/0
保真度	0.0550	0.1817	0.1267	[0.0377, 0.2104]	11/3/3

基座 fatal rate : 100.0% ; LoRA fatal rate : 17.6%。验证集仅 17 条，因此同时报告配对 bootstrap 区间和逐例方向。

5. 前后对比与 Goodhart 检查



案例 1 (样本 3) : base=0.0000 , LoRA=0.3500 , Δ =0.3500。总分明显提高，但图形落在画布外；改善主要是正确 namespace 与闭合结构，并非视觉成功。



案例 2 (样本 0) : base=0.1000 , LoRA=0.3500 , Δ =0.2500。总分轻微提高，但仅生成重复的浅色圆，提示保真度反而下降。



案例 3 (样本 5) : $\text{base}=0.0000$, $\text{LoRA}=0.0000$, $\Delta=0.0000$ 。基座与 LoRA 都未生成唯一完整 SVG，是明确的无变化失败。



案例 4 (样本 14) : $\text{base}=0.1000$, $\text{LoRA}=0.3500$, $\Delta=0.2500$ 。LoRA 输出可解析却是空白画布，fidelity 明显退化，构成典型 Goodhart 反例。

程序化分数仍不会理解叶片、动物或抽象品牌含义。图中的 INVALID SVG 卡片表示安全检查失败，不是伪造的渲染图。

6. 结论与局限

LoRA 将 fatal rate 从 100.0% 降至 17.6%，显示 270M 模型学会了正确 namespace 和完整闭合。但 14 个非致命输出中有 13 个触发背景/画布退化上限，因此不能宣称已解决视觉语义生成。更合理的后续方向是更强模型、逐步增加图元的课程、结构化 SVG tokenization，以及栅格/视觉模型评测。

7. 复现与验收

环境：macOS-27.0-arm64-arm-64bit；PyTorch 2.13.0；Transformers 4.57.6；PEFT 0.19.1。固定解码 seed=42，EOS token IDs=[1, 106]。单元测试、adapter 独立加载、数据哈希和逐样本输出分别见 tests/、adapter/、data_audit.json 和 results.json。